

最終レポート

テーマ：知的システム工学実験演習 II C101：統計情報処理

学生番号：242C2016

氏名：奥村直

知的システム工学科システム制御コース

2026 年 1 月 27 日

1 第1週

1.1 実験目的

第1週では、基本的な確率統計の知識と仮説検定について学び、演習を通して理解を深めることを目的とする。

1.2 原理・前提知識（統計解析の基礎）：第1週のまとめ

確率変数 … 確率的に値が決まる変数

事象・標本空間 … 試行によって起こり得る結果のことを事象といい、起こり得る結果の全体をその試行の標本空間という。

確率分布 … 確率変数の値に対応し、その値が起きる（得られる）確率をまとめたもの

平均 : $\mu = \sum_i p_i x_i = p_1 x_1 + p_2 x_2 + \sim + p_n x_n$

分散 : $\sigma^2 = \sum_i p_i (x_i - \mu)^2 = p_1 (x_1 - \mu)^2 + p_2 (x_2 - \mu)^2 + \sim + p_n (x_n - \mu)^2$

標準偏差 : $\sqrt{\sigma^2}$

二項分布 … 二項分布とは2つの結果のみの試行を n 回繰り返したときに、ある結果が k 回起こる確率に従う確率分布。

正規分布 … 連続的な確率変数を考察するときに用いられる確率密度関数

正規分布の確率密度関数 : $p(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{(x-\mu)^2}{2\sigma^2}\right]$

仮説検定 … 仮説では、設定されたある確率に従い事象が起きるはずである。しかし、実際に起きた事象を観測すると仮説が疑わしく感じることもある。仮説検定は、仮説を棄却するか採択するかを統計学的に判断する手法である。

有意水準 … 一般的には、帰無仮説 H が正しい場合でも誤って棄却してしまうことがある。仮説検定では、この誤りを第1種の過誤と呼び、第1種の過誤を犯す確率を有意水準と呼ぶ。

有意水準を単に低くして検定すると、棄却すべき帰無仮説を見逃してしまうことがあり、安易に有意水準は低くすることができない。また、この帰無仮説を見逃してしまうことを第2種の過誤という。

1.3 レポート課題1

表が0.6の確率で出るイカサマコインを購入した。購入したコインが実際に規格通りであることを確認するため、100回コイントスする試行により仮説検定を行う。（表の出る確率が0.6であることを確かめたい）ここで帰無仮説を H_0 「コインが規格通り製造されている」とする。

1.3.1 課題 (i)

演習 1 を参考に、表が 0.6 の確率で出るコインを 100 回コイントスしたときの二項分布をセット数 500 で確認し、頻度分布を示しなさい。

原理

二項分布で、頻度分布を調べるとその頻度の事象が起こる確率に相当する回数付近に結果が最も集まるようになる。今回は表が出た回数の頻度分布について調べているため、表の出る確率に相当する頻度付近に集中している。

ソースコード

Listing 1.1: kadai1

```
1 n = 100; % コイントス回数
2 numof_set = 500; % セット数
3 fre = zeros(n + 1, 1);
4
5 x = 0:n;
6
7 p_d = [0, 1]; % 裏=0, 表=1
8 w = [0.4, 0.6]; % 表が出る確率0.6
9
10 for i = 1:numof_set
11     s_d = datasample(p_d, n, 'Weights', w);
12     numof_heads = sum(s_d);
13     fre(numof_heads + 1) = fre(numof_heads + 1) + 1;
14 end
15
16 bar(x, fre);
17 title('表が出る確率のコインを回投げたときの二項分布0.6100');
18 xlabel('表が出た回数');
19 ylabel('頻度 (セット数)');
```

実験結果

上記ソースコードの実行結果として下（図 1.1: kadai1）に示すヒストグラムが得られた




図 1.1: kadai1i

考察

課題 (i) では、表が出る確率が 0.6 であるコインを 100 回投げる試行を 500 セット行い、表が出た回数の頻度分布を確認した。得られた頻度分布は、表の出る回数が 60 回付近を中心とした釣鐘型の分布となり、二項分布 $B(100, 0.6)$ の理論的な形状とよく一致していることが確認できた。

1.3.2 課題 (ii)

有意水準 5% で検定する際、100 回中何回表が出ると仮説が棄却されるか、その範囲を計算し、課題 (i) で得られた頻度分布にその範囲を示しなさい。

原理

否定されることを期待してたてる（無に帰すことを目的とした）仮説を**帰無仮説** H_0 といい、帰無仮説に対立する仮説を**対立仮説** H_1 という。

また、棄却されることが期待されている帰無仮説 H_0 が正しいのにも関わらず棄却してしまう間違いを第 1 種の過誤、本来は棄却すべき帰無仮説を正しいと判定してしまうことを第 2 種の過誤と呼ぶ。この課題 (ii) では、有意水準 5% で検定する際、100 回中何回表が出たときに棄却されるか、その範囲を求める。表が出た回数を x 、その事象が発生する確率を p 、試行回数を n とすると、ここでの標準正規分布は

$$Z = \frac{x - \mu}{\sigma} \quad (1.1)$$

より、

$$Z = \frac{x - np}{\sqrt{np(1-p)}} \quad (1.2)$$

と表現できる。

ソースコード

```

1  p = 0.6; %表が出る確率
2  n = 100; % コイントス回数
3  numof_set = 500; % セット数
4  fre = zeros(n + 1, 1);
5
6  x = 0:n;
7
8  p_d = [0, 1]; % 裏=0, 表=1
9  w = [0.4, 0.6]; % 表が出る確率0.6
10
11 for i = 1:numof_set
12     s_d = datasample(p_d, n, 'Weights', w);
13     numof_heads = sum(s_d);
14     fre(numof_heads + 1) = fre(numof_heads + 1) + 1;
15 end
16
17 bar(x, fre);
18 title('表が出る確率のコインを回投げたときの二項分布0.6100');
19 xlabel('表が出た回数');
20 ylabel('頻度 (セット数)');
21 np = n * p;
22 npq = n * p * (1 - p); %平均、分散の定義
23 variant1 = -1.96 * sqrt(npq) + np; %棄却域
24 variant2 = 1.96 * sqrt(npq) + np; %棄却域の算出
25 xline(variant1, '-', '棄却域', 'Color', 'r'); %棄却域を赤の実線で書き込む
26 xline(variant2, '-', '棄却域', 'Color', 'r'); %棄却域を赤の実線で書き込む
27 legend('頻度分布', ...
28     strcat('棄却域：限界値:', num2str(variant1)), ...
29     strcat('棄却域：限界値:', num2str(variant2))); %説明の追加
30 title(strcat('レポート課題 1 課題(ii)')); %タイトル表示

```

実験結果




図 1.2: kadai1ii

考察

図 1.2: kadai1ii を見ると、0 回から約 50 回または 70 回から約 100 回表が出るとこの仮説は棄却されるということが分かった。

1.3.3 課題 (iii)

(i) の状況では仮説を棄却しないことが正しいが 500 セット中で何回仮説を棄却してしまったか確認し、仮説検定において有意水準によって第 1 種の過誤を侵す確率を制御できていることを確認しなさい。

原理

課題 (ii) で説明していた、第 1 種の過誤が発生する確率を **有意水準** という。ここでは仮説を棄却しないことが正しいため、第 1 種の過誤（正しいにも関わらず仮説が棄却されること）の可能性があるセットは棄却域に分布しているセットである。そのセットを数えて、数えたセットが全体のセットの数に対して何割かを算出すればよい。算出した結果が 0.05 付近であれば、制御できていると考えてよい。

結果・考察

図 1.2 を見て、棄却域にあるセットを目視で計上した。すると 22 セットあると分かったので原理で言及した割合を算出する。有意水準 ϕ は、

$$\phi = \frac{22}{500} = 0.044...[\%] \quad (1.3)$$

結果より、計算結果が有意水準 5% 付近であるから、仮説検定において有意水準によって第 1 種の過誤を侵す確率を制御できていることを確認できた。

2 第2週

2.1 実験目的

第 2 週では、代表的な乱択アルゴリズムであるモンテカルロ法を学んで乱択アルゴリズムについての理解を深める。

2.2 原理・前提知識（モンテカルロ法）：第 2 週のまとめ

乱択アルゴリズム

乱択アルゴリズムとは、無作為抽出を含むアルゴリズムのことである。基本的な考え方は、解析的には解くことができなかったり、解くことが（計算量的に）非常に難しい問題に乱択を導入することで確定的な解を得ることを諦め、確率的な解を得る方法である。確定的な解を得ることを諦める代わりに現実的な計算時間で確率的な解を得ようという考え方である。また、乱択アルゴリズムに共通する特徴としては、ある精度を保証するために必要な乱択の回数は、問題の複雑さや難しさに依存せずに決まることにある。また、アルゴリズムの実装、並列化も容易である。

決定論的な問題への簡単な適応例として円周率 π をモンテカルロ法で求めることを考えよう。 $x_i \in [0, 1], y_i \in [0, 1]$ をそれぞれ一様乱数とし、N 組のサンプルに対して、

$$x_i^2 + y_i^2 \leq 1 \quad (2.1)$$

を満たす組の数を S とする。与式を満たす確率は、正方形と $\frac{1}{4}$ 円の面積比 $\frac{\pi}{4}$ に比例するはずであるから、円周率 π の近似値は

$$\pi \approx \frac{4S}{N} \quad (2.2)$$

と求められる。

定理 1：大数の弱法則

確率変数 $X_1, X_2, \dots, X_N$ が独立であって、それらの平均が $E(X_k) = \mu (\forall k)$ 、かつ、一定の定数 σ に対して $V(X_k) \leq \sigma^2 (\forall k)$ であるならば、N が十分大きくなると $\tilde{X} = \frac{1}{N} \sum_{k=1}^N X_k$ は μ に確率収束する。つまり、任意に与えられる整数 $\epsilon > 0$ に対して

$$\lim_{N \rightarrow \infty} P(|\tilde{X} - \mu| < \epsilon) = 1 \quad (2.3)$$

この定理 1 によって、試行回数を大きくすれば近似値が真値に近づくことが保障される。ただし、試行回数を増やすほど、近似値が単調に真値に近づくとは述べていない。さらに、近似の制度を見積もるためには次の定理が重要である。

定理 2：中心極限定理

確率変数 $X_1, \dots, X_N$ が平均 μ 、分散 σ^2 の独立同分布の確率変数とする。n が十分大きければ $\tilde{X} = \frac{1}{N} \sum_{k=1}^N X_k$ は平均 μ 、分散 $\frac{\sigma^2}{N}$ の正規分布に従う。この中心極限定理を用いて近似制度を見積もってみる。確率変数 X_k を k 回目の試行で条件を満たす場合に 1、満たさない場合に 0 をとるものとする。このようにすると、 $\tilde{X}$ は相対度数 $\frac{S}{N}$ に等しい。また、 X_k の平均 $E(X_k)$ と分散 $V(X_k)$ は、真の確率を $I(= \frac{\pi}{4})$ とすると、

$$E(X_k) = I \quad (2.4)$$

$$V(X_k) = I(1-I)^2 + (1-I)(0-I)^2 = I(1-I) \quad (2.5)$$

である。これらと中心極限定理より $\tilde{X}$ の平均 $E(\tilde{X})$ と分散 $V(\tilde{X})$ は

$$E(\tilde{X}) = I \quad (2.6)$$

$$V(\tilde{X}) = \frac{1}{N} I(1-I) \quad (2.7)$$

となる。

円周率を求めるこの例題の場合、信頼度 99% で I の真の値は

$$\frac{S}{N} \pm \frac{2.5758}{4} \sqrt{\frac{\pi(4-\pi)}{N}} \quad (2.8)$$

の区間に含まれる。およそ 10000 回の試行で信頼区間は約 ± 0.01 となる。また、信頼区間の幅を $\frac{1}{10}$ 倍にするためには、試行回数 N を 100 倍にする必要があることが分かる。

2.3 レポート課題 2

2.3.1 課題 (i)

セットあたりの試行回数を $10^2, 10^3, 10^4$ と増加させて【演習 6】と同様にグラフにプロットして、平均、分散も確認して「大数の法則」、「中心極限定理」について考察しなさい。

原理

原理については節「原理・前提知識（モンテカルロ法）：第 2 週のまとめ」の大数の法則と中心極限定理を参照。

ソースコード

Listing 2.1: 大数の法則・中心極限定理

```

1 clear; close all; %初期化
2 N=2:4; %試行回数 10^2~10^4
3 numof_set=100;
4 step=5^(N(1)-1)/(10^N(1));
5 min_x=pi-(0.5+step*0.5); %下限
6 max_x=pi+(0.5+step*0.5); %上限
7 Region=[min_x,max_x;0,numof_set]; %ヒストグラム描画の領域設定
8 title('中心極限定理の確認');
9 for e=1:length(N)
10 subplot(1,length(N),e); %同一ウィンドウにグラフを複数描画
11 plot([pi,pi],[0,numof_set]); %y=pi の線を描画
12 legend('真の円周率');
13 xlabel({'推定された円周率',sprintf('試行回数(:%d)',10^N(e))});

```



```

14 ylabel('頻度');
15 hold on;
16 end
17 i_est=zeros(length(N),numof_set); %推定結果格納用
18 for e=1:length(N) %セットあたりの試行回数が同じセットをまとめて実行1
19     numof_try=10^N(e);
20     %ベクトル演算%%%%%%%%%%%%
21     x=rand(numof_try,numof_set); %乱択で選ばれた x 座標(×numof_trynumof_set の配列)
22     y=rand(numof_try,numof_set); %乱択で選ばれた y 座標(×numof_trynumof_set の配列)
23     cnt=sum(((x.^2+y.^2)<=1),1); %x^2+y^2<1 が真(%t)となった要素数
24     i_est(e,:)=cnt/numof_try; % $\pi/4$  の推定結果を格納
25     %%%%%%%%%%%%%
26     fprintf('-----\n');
27     fprintf('試行回数: %d\n',10^N(e));
28     fprintf('平均 : %.5f\n',mean(i_est(e,:)*4)); % $\pi (=4I)$  の推定値について
29     fprintf('標準偏差: %.8f\n',std(i_est(e,:)*4)); %統計量を計算、表示
30     subplot(1,length(N),e);
31     histogram(i_est(e,:)*4,min_x:step:max_x);
32 end

```

実験結果




図 2.1: kadai2i1




図 2.2: kadai2i2




図 2.3: kadai12i3

Listing 2.2: kadai2i

```

1  -----試行回数
2  : 100平均
3  : 3.11440標準偏差
4  : 0.15979987
5  -----試行回数
6  : 1000平均
7  : 3.15028標準偏差
8  : 0.06354956
9  -----試行回数
10 : 10000平均
11 : 3.14030標準偏差
12 : 0.01696000

```

考察

セットあたりの試行回数を $10^2, 10^3, 10^4$ と変化させ、それぞれについて推定された円周率の分布、平均および分散を確認した。まず平均値に注目すると、試行回数が 10^2 の場合には平均値は真の円周率 π からややずれているが、 $10^3, 10^4$ と試行回数を増加させるにつれて、平均値は真の値に近づいていることが分かる。これは、試行回数が十分に大きくなると標本平均が期待値に収束するという 大数の法則 を反映した結果である。次に分散を見ると、試行回数の増加に伴って値が大きく減少しており、推定値のばらつきが小さくなっていることが確認できる。実際に、標準偏差はおおよそ試行回数の平方根に反比例して減少しており、試行回数が増えるほど推定精度が向上している。また、ヒストグラムの形状に着目すると、試行回数が少ない 10^2 では分布がやや歪んでいるのに対し、 $10^3, 10^4$ では平均値の周りに左右対称な釣鐘型の分布に近づいている。これは、各試行結果の分布に関わらず、標本平均の分布が正規分布に近づくという 中心極限定理 を示している。

2.3.2 課題 (ii-a)

$10^2, 10^3, 10^4$ の各試行回数の1セットについて、それぞれ、(2.8) 式にて示された 99% 信頼区間に真の確率 $I(= \frac{\pi}{4})$ が得られているセットの総数を求めるコマンドをプログラムに追加し、得られた結果から信頼区間について考察しなさい。

ソースコード

Listing 2.3: セット総数を求められるよう修正したプログラム

```

1  clear; close all; %初期化
2  N=2:4; %試行回数 10^2~10^4
3  numof_set=100; %セット数
4  step=5^(N(1)-1)/(10^N(1)); %ヒストグラムのピン幅
5  min_x=pi-(0.5+step*0.5); %描画用頻度集計の下限
6  max_x=pi+(0.5+step*0.5); %描画用頻度集計の上限
7  Region=[min_x,max_x;0,numof_set]; %ヒストグラム描画の領域設定
8  title('中心極限定理の確認');
9  for e=1:length(N)
10 subplot(1,length(N),e); %同一ウィンドウにグラフを複数描画
11 plot([pi,pi],[0,numof_set]); %y=pi の線を描画
12 legend('真の円周率');
13 xlabel({'推定された円周率',sprintf('試行回数(:%d)',10^N(e))});
14 ylabel('頻度');
15 hold on;
16 end
17 i_est=zeros(length(N),numof_set); %推定結果格納用

```

```

19 for e=1:length(N) %セットあたりの試行回数が同じセットをまとめて実行1
20 numof_try=10^N(e);
21 x=rand(numof_try,numof_set); %乱択で選ばれた x 座標(×numof_trynumof_set の配列)
22 y=rand(numof_try,numof_set); %乱択で選ばれた y 座標(×numof_trynumof_set の配列)
23 cnt=sum(((x.^2+y.^2)<=1),1); %x^2+y^2<1 が真(%t)となった要素数
24 i_est(e,:)=cnt/numof_try; %π/4 の推定結果を格納
25 var1=i_est(e,:)+2.5758/4*sqrt(pi*(4-pi)/numof_try); %信頼区間の限界値を計算
26 var2=i_est(e,:)-2.5758/4*sqrt(pi*(4-pi)/numof_try); %信頼区間の限界値を計算
27 turecnt=sum((var2<=(pi/4) & (pi/4)<=var1));%信頼区間に I がある時のセット総数の算出
28 fprintf('-----\n');
29 fprintf('試行回数: %d\n',10^N(e));
30 fprintf('平均 : %.5f\n',mean(i_est(e,:)*4)); %π(=4I)の推定値について
31 fprintf('標準偏差: %.8f\n',std(i_est(e,:)*4)); %統計量を計算、表示
32 fprintf('信頼区間内にあるセット数: %d\n', turecnt);
33 subplot(1,length(N),e);
34 histogram(i_est(e,:)*4,min_x:step:max_x);
35 end

```

実験結果

Listing 2.4: 課題 (ii-a) 実験結果

```

1 -----試行回数
2 : 100平均
3 : 3.13320標準偏差
4 : 0.16663563信頼区間内にあるセット数
5 : 99
6 -----試行回数
7 : 1000平均
8 : 3.13800標準偏差
9 : 0.05140923信頼区間内にあるセット数
10 : 99
11 -----試行回数
12 : 10000平均
13 : 3.14645標準偏差
14 : 0.01539180信頼区間内にあるセット数
15 : 99

```

考察

2.3.3 課題 (ii-b)

同様に、95% 信頼区間についても確認しなさい。(2.8) 式の信頼区間、2.5758 を 1.9600 に変更する。信頼区間を 95% に変更すると、ソースコードは以下の通りである。

ソースコード

Listing 2.5: 95%信頼区間

```

1 clear; close all; %初期化
2 N=2:4; %試行回数 10^2~10^4
3 numof_set=100; %セット数
4 step=5^(N(1)-1)/(10^N(1)); %ヒストグラムのピン幅
5 min_x=pi-(0.5+step*0.5); %描画用頻度集計の下限
6 max_x=pi+(0.5+step*0.5); %描画用頻度集計の上限
7 Region=[min_x,max_x;0,numof_set]; %ヒストグラム描画の領域設定
8 title('中心極限定理の確認');

```

```

9  for e=1:length(N)
10 subplot(1,length(N),e); %同一ウィンドウにグラフを複数描画
11 plot([pi,pi],[0,numof_set]); %y  $\pi$ = の線を描画
12 legend('真の円周率');
13 xlabel({'推定された円周率',sprintf('試行回数(:%d)',10^N(e))});
14 ylabel('頻度');
15 hold on;
16 end
17 i_est=zeros(length(N),numof_set); %推定結果格納用
18 for e=1:length(N) %セットあたりの試行回数が同じセットをまとめて実行1
19 numof_try=10^N(e);
20 x=rand(numof_try,numof_set); %乱択で選ばれた x 座標( $\times$  numof_trynumof_set の配列)
21 y=rand(numof_try,numof_set); %乱択で選ばれた y 座標( $\times$  numof_trynumof_set の配列)
22 cnt=sum((x.^2+y.^2)<=1),1); % $x^2+y^2<1$  が真(%t)となった要素数
23 i_est(e,:)=cnt/numof_try; % $\pi/4$  の推定結果を格納
24 var1=i_est(e,:)+1.9600/4*sqrt(pi*(4-pi)/numof_try); %信頼区間の限界値を計算
25 var2=i_est(e,:)-1.9600/4*sqrt(pi*(4-pi)/numof_try); %信頼区間の限界値を計算
26 turecnt=sum((var2<=(pi/4) & (pi/4)<=var1));%信頼区間に I がある時のセット総数の算出
27 fprintf('-----\n');
28 fprintf('試行回数: %d\n',10^N(e));
29 fprintf('平均: %.5f\n',mean(i_est(e,:)*4)); % $\pi$  (=4I) の推定値について
30 fprintf('標準偏差: %.8f\n',std(i_est(e,:)*4)); %統計量を計算、表示
31 fprintf('信頼区間内にあるセット数: %d\n', turecnt);
32 subplot(1,length(N),e);
33 histogram(i_est(e,:)*4,min_x:step:max_x);
34 end

```

実験結果

Listing 2.6: 実験結果 iib

```

1  -----試行回数
2  : 100平均
3  : 3.13600標準偏差
4  : 0.17244528信頼区間内にあるセット数
5  : 95
6  -----試行回数
7  : 1000平均
8  : 3.14388標準偏差
9  : 0.05144680信頼区間内にあるセット数
10 : 96
11 -----試行回数
12 : 10000平均
13 : 3.14128標準偏差
14 : 0.01585962信頼区間内にあるセット数
15 : 97

```

考察

上記の結果より、95% の信頼区間で得られた真の確率のセット数は、それぞれの試行回数に対して、100 セットあたり 95、96、97 であるため、この実験結果は信頼区間の定義を満たしている。

3 第3週

3.1 目的

第3週では、共分散および、行列の対角化を用いた分析について理解することを目的とする。

3.2 原理・前提知識（共分散の基礎）

共分散

2つの確率変数 X_1, X_2 があり、その平均が $\mu_1 = E[X_1], \mu_2 = E[X_2]$ であったとする。 X_2 の共分散 $Cov(X_1, X_2)$ は

$$Cov(X_1, X_2) = E[(X_1 - \mu_1)(X_2 - \mu_2)] \quad (3.1)$$

で定義される。

共分散の持つ性質

(i) $Cov(X_1, X_2) = E[X_1 X_2] - E[X_1] E[X_2]$

(ii) X の分散 $V(X) = Cov(X, X)$

(iii) $Cov(X_1, X_2) = Cov(X_2, X_1)$

(iv) X_1 と X_2 が独立ならば $Cov(X_1, X_2) = 0$

ただし、 $V(X)$ は確率変数 X の分散を表す。

共分散行列

以下に共分散行列を示す。

$$\begin{bmatrix} V(X_1) & Cov(X_1, X_2) \\ Cov(X_2, X_1) & V(X_2) \end{bmatrix} \quad (3.2)$$

また、上記の行列は以下のように書き換えることができる。

$$E[(X - \mu)(X - \mu)^T] \quad (3.3)$$

独立な確率変数の結合分布

2つの確率変数 X_1 と X_2 が独立の場合について考える。確率変数 X_1, X_2 は独立であり、それぞれ $\mathcal{N}(\mu_1, (\sigma_1)^2)$ $\mathcal{N}(\mu_2, (\sigma_2)^2)$ の正規分布に従うものとする。ただし、1次元の正規分布 $\mathcal{N}(\mu, (\sigma)^2)$ の確率密度関数は

$$p(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{(x - \mu)^2}{2\sigma^2}\right] \quad (3.4)$$

このとき、 X_1, X_2 の結合分布の確率密度関数を求めてみる。確率密度関数はそれぞれ

$$p(x_1) = \frac{1}{\sqrt{2\pi\sigma_1^2}} \exp\left[-\frac{(x_1 - \mu_1)^2}{2\sigma_1^2}\right], p(x_2) = \frac{1}{\sqrt{2\pi\sigma_2^2}} \exp\left[-\frac{(x_2 - \mu_2)^2}{2\sigma_2^2}\right] \quad (3.5)$$

である。 X_1, X_2 は独立であるので結合分布の確率密度関数はそれぞれの確率密度関数の積となる。つまり、

$$p(x) = p\left(\begin{bmatrix} x_1 \\ x_2 \end{bmatrix}\right) = p(x_1)p(x_2) \quad (3.6)$$

共分散行列の意味

前節では、確率変数が独立な場合、つまり共分散が 0 の 2 次元正規分布の様子と共分散行列の関係を確認した。ここでは共分散が 0 ではない場合の共分散行列の意味について考える。

共分散行列 P は定義より対称行列である（つまり $P = P^T$ を満たす）。対称行列の性質から、固有ベクトルはすべて互いに直交するように選ぶことができる。そこで、共分散行列 P の固有ベクトル $\mathbf{u}_i$ を正規直交系（長さが 1 で互いに直交）となるように以下を満たすように定める。

$$P\mathbf{u}_i = \lambda_i \mathbf{u}_i \quad (3.7)$$

$$\mathbf{u}_i^T \mathbf{u}_j = \begin{cases} 1 & (i = j) \\ 0 & (i \neq j) \end{cases} \quad (3.8)$$

そしてこれらの固有ベクトル $\mathbf{u}_i$ を用いて行列 U を以下のように定める。

$$U = [\mathbf{u}_1 \ \mathbf{u}_2 \ \cdots \ \mathbf{u}_n] \quad (3.9)$$

(3.8) 式の関係から

$$U^T U = I \quad (\text{つまり } U^T = U^{-1}) \quad (3.10)$$

である。また、(3.7) 式の関係から

$$PU = U\Lambda, \quad \text{ただし } \Lambda = \begin{bmatrix} \lambda_1 & & 0 \\ & \ddots & \\ 0 & & \lambda_n \end{bmatrix} \quad (3.11)$$

これより

$$U^T P U = \Lambda \quad (3.12)$$

と対角化される。

この U を用いて確率変数の座標変換を行う。

$$\mathbf{z} = U^T \mathbf{x} \quad (3.13)$$

で新たな確率変数ベクトル $\mathbf{z}$ を定義する。この $\mathbf{z}$ の共分散行列を求めてみると

$$\begin{aligned} E[(\mathbf{z} - \boldsymbol{\mu}_z)(\mathbf{z} - \boldsymbol{\mu}_z)^T] &= E[U^T(\mathbf{x} - \boldsymbol{\mu})\{U^T(\mathbf{x} - \boldsymbol{\mu})\}^T] \\ &= E[U^T(\mathbf{x} - \boldsymbol{\mu})(\mathbf{x} - \boldsymbol{\mu})^T U] \\ &= U^T E[(\mathbf{x} - \boldsymbol{\mu})(\mathbf{x} - \boldsymbol{\mu})^T] U \\ &= U^T P U = \Lambda \end{aligned} \quad (3.14)$$

ただし、 $\boldsymbol{\mu}_z = U^T \boldsymbol{\mu}$ である。

これより、確率変数ベクトル $\mathbf{z}$ の共分散行列は対角行列となる。つまり、独立な場合の共分散行列と同じ形となる。これは、座標変換された座標 ($\mathbf{z}$) で見ると、楕円確率楕円（体）上で確率密度が等しくなる分布になることを意味している（図 8.4）。

$$\mathbf{x} = U\mathbf{z} \quad (3.15)$$

であることから、座標変換前の座標 ($\mathbf{x}$) での分布を表す楕円体の軸の方向は

$$U \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \mathbf{u}_1, \quad U \begin{bmatrix} 0 \\ 1 \end{bmatrix} = \mathbf{u}_2 \quad (3.16)$$

となり、共分散行列の固有ベクトル $\mathbf{u}_i$ が軸方向を表していることがわかる。さらに、楕円体の径（つまりばらつきの大きさ）は、共分散行列の固有値 $\lambda_i (= \sigma_i^2)$ によって与えられる。

上式より、 $\mathbf{z}$ の確率密度関数は

$$\frac{1}{\sqrt{(2\pi)^n \det \Lambda}} \exp \left[-\frac{1}{2} (\mathbf{z} - \boldsymbol{\mu}_z)^T \Lambda^{-1} (\mathbf{z} - \boldsymbol{\mu}_z) \right] \quad (3.17)$$

となる。これを用いて $\mathbf{x}$ で書き直すと

$$\begin{aligned} & \frac{1}{\sqrt{(2\pi)^n \det \Lambda}} \exp \left[-\frac{1}{2} (\mathbf{z} - \boldsymbol{\mu}_z)^T \Lambda^{-1} (\mathbf{z} - \boldsymbol{\mu}_z) \right] \\ &= \frac{1}{\sqrt{(2\pi)^n \det U^T \Lambda \det U}} \exp \left[-\frac{1}{2} U^T (\mathbf{x} - \boldsymbol{\mu})^T \Lambda^{-1} U^T (\mathbf{x} - \boldsymbol{\mu}) \right] \\ &= \frac{1}{\sqrt{(2\pi)^n \det (U \Lambda U^T)}} \exp \left[-\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^T U \Lambda^{-1} U^T (\mathbf{x} - \boldsymbol{\mu}) \right] \\ &= \frac{1}{\sqrt{(2\pi)^n \det P}} \exp \left[-\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^T P^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right] \end{aligned} \quad (3.18)$$

となる。なお、式変形の途中で次の三つのことを用いた。

- (i) 二つの行列積 AB の転置は $(AB)^T = B^T A^T$ である。
- (ii) 二つの正方行列の積 AB の逆行列は $(AB)^{-1} = B^{-1} A^{-1}$ である。
- (iii) 二つの正方行列の積 AB の行列式は $\det AB = \det A \det B$ である。

共分散行列が分かることで、どちら方向に（共分散行列の固有値）データがばらついているかを知ることができる。図 8.2 に二次元正規分布の場合の確率密度関数の様子を示した。共分散行列 P の固有ベクトルが分布を表す楕円体の主軸方向 $\mathbf{u}_1, \mathbf{u}_2$ を定め、それぞれの方向のばらつき合（標準偏差）は P の固有値の平方根 $\sqrt{\lambda_i}$ である。

3.3 レポート課題3

日本人女性（20～60 歳）166 名分の身長、体重のデータを用いて以下の設問に答える。また、設問ごとではなく最後に総合して考察を記している。

3.3.1 課題 (i)

身長、体重の平均、分散、共分散を求めよ。

解答

ここでは、身長、体重の平均、分散、共分散、共分散行列を求める。用いる理論・原理は前節に記した通りである。

ソースコード

Listing 3.1: 身長、体重の平均、分散、共分散、共分散行列

```
1 load("BodySizeF.mat")
2 % 身長と体重の平均
3 mh_ave=sum(dataf(:,1))/length(dataf(:,1));
4 mw_ave=sum(dataf(:,2))/length(dataf(:,2));
5 % 身長と体重の分散
6 mh_var=sum((dataf(:,1)-mh_ave).^2)/length(dataf(:,1));
```

```

7 mw_var=sum((dataf(:,2)-mw_ave).^2)/length(dataf(:,2));
8 % 身長と体重の標準偏差
9 mh_std=sqrt(mh_var);
10 mw_std=sqrt(mw_var);
11 % 身長と体重の共分散
12 mhw_cov=sum((dataf(:,1)-mh_ave).*(dataf(:,2)-mw_ave))/length(dataf(:,1));
13 % 共分散行列
14 phw=[mh_var,mhw_cov;mhw_cov,mw_var];
15 %表示
16 fprintf('身長の平均: %.5f\n', mh_ave);
17 fprintf('体重の平均: %.5f\n', mw_ave);
18 fprintf('身長の分散: %.8f\n', mh_var);
19 fprintf('体重の分散: %.8f\n', mw_var);
20 fprintf('身長と体重の共分散: %.8f\n', mhw_cov);

```

実験結果

身長の平均: 156.47771
 体重の平均: 51.56849
 身長の分散: 30.34522609
 体重の分散: 53.48531400
 身長と体重の共分散: 12.21144234

3.3.2 課題 (ii)

身長、体重の散布図、ヒストグラムを表示せよ

ソースコード

身長・体重の散布図、ヒストグラムを表示するプログラムを以下に示す。

Listing 3.2: 身長・体重の散布図、ヒストグラムを表示するプログラム

```

1 figure; %描画ウィンドウを作成
2 ph=plot(dataf(:,1),dataf(:,2),'r'); %散布図の描画
3 ph.MarkerSize=20; %マーカーのサイズ変更
4 ph.MarkerEdgeColor='black'; %マーカーの色変更
5 daspect([1,1,1]) %x-y 軸の比率を 1:1 に
6 grid on;
7 %ラベル
8 xlabel('身長[cm]');
9 ylabel('体重[kg]');
10
11 % 2 次元の頻度を計算し、2 次元ヒストグラムを表示
12 mhlist=140:5:170; %身長の階級(5cm 幅)
13 mwlist=30:5:75; %体重の階級(5kg 幅)
14 % 2 次元頻度の計算
15 mdist=zeros(length(mhlist)-1,length(mwlist)-1); %頻度を格納する配列
16 for hidx=1:length(mhlist)-1
17 ht=dataf(:,1)>=mhlist(hidx) & dataf(:,1)<mhlist(hidx+1);
18 for widx=1:length(mwlist)-1
19 wt=dataf(:,2)>=mwlist(widx) & dataf(:,2)<mwlist(widx+1);
20 mdist(hidx,widx)=sum(ht & wt);
21 end
22 end
23 % 2 次元ヒストグラムの 3D 表示

```

```

24 figure; %描画ウィンドウの生成
25 bar3(mdlist); %ヒストグラムの描画
26 ax=gca;
27 ax.XTick=(1:length(mwlist))-0.5; %目盛りの振り替え
28 ax.YTick=(1:length(mhlist))-0.5;
29 axis([0.5,length(mwlist)-0.5,0.5,length(mhlist)-0.5,0,inf]);
30 ax.XTickLabel=[mwlist,100];
31 ax.YTickLabel=[mhlist,185];
32 daspect([1,1,2]); %x-y 軸の比率を 1:1 に
33 %ラベル
34 xlabel('体重[kg]');
35 ylabel('身長[cm]');
36 zlabel('頻度');
37 % 2次元分布の 3D 補間表示
38 figure; %描画ウィンドウの生成
39 surf(mhlist(2:end)-2.5,mwlist(2:end)-2.5,mdist','FaceColor','interp');
40 daspect([1,1,0.5]); %x-y 軸の比率を 1:1 に
41 xlabel('身長[cm]');
42 ylabel('体重[kg]');
43 zlabel('頻度');

```

実験結果

ソースコードを実行して得られたヒストグラムと散布図を以下に示す。




図 3.1: グラフ 1




図 3.2: ヒストグラム




図 3.3: 散布図

3.3.3 課題 (iii)

(i) で求めた共分散行列を共分散とする正規分布の密度関数を表示せよ。ただし、正規分布近似が妥当かどうか検討するために、(ii) と比較できるように平均値やスケールも考慮した密度関数を表示すること。

ソースコード

ソースコードを示す。

Listing 3.3: 確率密度関数を表示するプログラム

```
1 m=[156.47771;51.56849]; %平均
2 %共分散行列  ^^e2^^9e^^a4 phw
3 % 密度関数の計算
4 [x,y]=meshgrid(140:5:170, 30:5:75); %二次元格子点の生成
5 idx=size(x);
6 z=zeros(idx(1),idx(2));
7 for i=1:idx(1)
8 for j=1:idx(2)
9 xy=[x(i,j);y(i,j)]-m;
10 z(i,j)=1/(2*pi*sqrt(det(phw)))*exp(-xy'/phw*xy/2);
11 %格子点での確率密度値の計算
12 end
13 end
14 %密度関数の 3D 表示
15 figure;
16 surf(x,y,z,'Facecolor','interp');
17 daspect([1,1,0.01]);
18 colormap(jet);
19 [v,d]=eig(phw);
20 xlabel('身長[cm]');
21 ylabel('体重[kg]');
```

実験結果

以下に実験結果として、確率密度関数を示す。




図 3.4: kadai3iii

3.3.4 課題 (iv)

共分散行列の主軸を散布図に加えて表示せよ

ソースコード

共分散行列の主軸の散布図を実装した。プログラムを以下に示す。

Listing 3.4: 散布図を表示するプログラム

```
1 figure;
2 ph=plot(dataf(:,1),dataf(:,2),'r');
3 ph.MarkerSize=20;
4 ph.MarkerEdgeColor='black';
5 daspect([1,1,1]);
6 grid on; hold on;
7 [pv,pd]=eig(phw);
8
9 hwtmp1=[mh_ave;mw_ave]*ones(1,3)+pv(:,1)*(-1:1)*sqrt(pd(1,1))*3;
10 hwtmp2=[mh_ave;mw_ave]*ones(1,3)+pv(:,2)*(-1:1)*sqrt(pd(2,2))*3;
11
12 % 主軸の表示
13 plot(hwtmp1(1,:),hwtmp1(2,:));
14 plot(hwtmp2(1,:),hwtmp2(2,:));
15
16 xlabel('身長[cm]');
17 ylabel('体重[kg]');
```

実験結果

上記のプログラムを実行して得られた散布図を以下に示す。

3.3.5 課題 (v)

身長が分かった場合の条件付き分布の平均はどのような直線となるか、散布図に加えて表示せよ。

ソースコード

条件付き分布の平均がどのような直線をとるか、直線を実装したプログラムを以下に示す。

Listing 3.5: 条件付き分布の平均

```
1 mw_ave+phw(2,1)/phw(1,1)*(160-mh_ave); %身長 160cm の時の体重の平均
2 % 演習 12 でやったことを行う
3 figure;
4 ph=plot(dataf(:,1),dataf(:,2),'r');
5 ph.MarkerSize=20;
6 ph.MarkerEdgeColor='black';
7 daspect([1,1,1]);
8 grid on; hold on;
9 [pv,pd]=eig(phw);
10 hwtmp1=[mh_ave;mw_ave]*ones(1,3)+pv(:,1)*(-1:1)*sqrt(pd(1,1))*3;
11 hwtmp2=[mh_ave;mw_ave]*ones(1,3)+pv(:,2)*(-1:1)*sqrt(pd(2,2))*3;
12 % 主軸の表示
13 plot(hwtmp1(1,:),hwtmp1(2,:));
14 plot(hwtmp2(1,:),hwtmp2(2,:));
15
16 mh_range=[140,170];
```





図 3.5: 主軸を加えた散布図

```

17
18 plot(mh_range,mw_ave+phw(2,1)/phw(1,1)*(mh_range-mh_ave),'g');
19
20 xlabel('身長[cm]');
21 ylabel('体重[kg]');

```

実験結果

上記のプログラムを実行して得られた散布図を以下に示す。




図 3.6: 条件付き平均の分布、散布図

3.4 考察

この課題では、日本人女性のデータから、身長と体重の統計的特徴を分析した。

課題 (i) では、身長・体重それぞれの平均、分散、共分散を求めた。また、 $E[(X - \mu)(X - \mu)^T]$ を用いて共分散行列も求めた。ここで、共分散行列は身長と体重の相互関係を記述するものである。

課題 (ii) , 課題 (iii) において、実際の統計データ（ここでは身長と体重）が二次元正規分布の確率密度関数によって高い精度で近似できることを確認した。共分散行列を用いることで変数の相関を考慮した n 次元の正規分布へと拡張できるということが分かる。

さらに、課題 (iv) (v) では、共分散行列の固有値を用いた分析をした。共分散行列が分かることで直交行列により対角化して座標変換を施すことで、相関のある変数それぞれ独立な変数として分解することができる。散布図に描画した主軸は、固有ベクトルの方向で、標本のばらつきが最も分散する方向を示している。一方、条件付き平均の直線は主軸と異なる傾きとなっている。

4 第4週

4.1 目的

第4週では、ベイズ統計について理解することを目的とする。

4.2 原理・前提知識（ベイズ統計基礎）

統計的情報処理では、複数の確率変数に対してそれらの関わりを解析することが重要である。複数の確率変数の関係を考慮する第一歩として、まずは以下の三つの確率を考える。

- 周辺確率 $P(A) \Rightarrow$ 事象 A が起きる確率
- 同時確率 $P(A \cap B) \Rightarrow$ 事象 A と B が同時に起きる確率
- 条件付き確率 $P(A | B) \Rightarrow$ 事象 B が起きたという条件の下での事象 A が起きる確率

周辺確率と同時確率の関係は、以下の式で表される。

$$P(A) = \sum_B P(A \cap B) \quad (4.1)$$

このように、複数の確率変数に関する同時確率分布から、興味ある確率変数のみに注目した周辺確率だけを取り出すことを周辺化と呼ぶ。条件付き確率との関係は、 $0 < P(B)$ のとき、

$$P(A \cap B) = P(A | B)P(B) \quad (4.2)$$

となる。これは、事象 B が起きたという条件の下での事象 A が起きる確率と、事象 B が起きる確率との積をとると、事象 A と B の同時確率となることを表しており、直感的に理解しやすい。また、周辺化の式から、条件付き確率と周辺確率の関係は、以下の式で表される。

$$P(A) = \sum_B P(A | B)P(B) \quad (4.3)$$

ここで、式を変形して条件付き確率についてまとめると、

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)} = \frac{P(A \cap B)}{\sum_A P(B \mid A)P(A)} \quad (4.4)$$